TRƯỜNG ĐẠI HỌC SÀI GÒN

KHOA CÔNG NGHỆ THÔNG TIN



BÀI TẬP LÝ THUYẾT – EX06

XÁC SUẤT, MẠNG BAYES VÀ RA QUYẾT ĐỊNH TRONG AI

Môn: Advanced Artificial Intelligence

Giảng viên hướng dẫn:	**Thầy Đỗ Như Tài**
Họ và tên sinh viên:	**Bùi Minh Trung**
Mã số sinh viên (MSSV):	**3124720074**
Lớp chuyên ngành:	**DNT1241**

TP. HỒ CHÍ MINH – NĂM 2026

PHẦN TỔNG QUAN & MỤC TIÊU HỌC TẬP

Mục tiêu học tập của bài tập lý thuyết EX06 bao gồm:

- Vận dụng quy tắc Bayes để cập nhật xác suất hậu nghiệm khi có bằng chứng mới (Belief Updating).
- Phân tích tính độc lập vô điều kiện và độc lập có điều kiện giữa các biến ngẫu nhiên (d-separation, Markov blanket).
- Biểu diễn phân phối xác suất chung bằng mạng Bayes (Bayesian Network) và bảng xác suất có điều kiện (CPT).
- Thực hiện suy luận chính xác bằng phép lấy tổng/triệt tiêu biến (Enumeration / Variable Elimination) và mô tả suy luận xấp xỉ bằng lấy mẫu (Prior Sampling, Rejection Sampling, Likelihood Weighting, Gibbs Sampling/MCMC).
- Tính tiện ích kỳ vọng (Expected Utility - EU) và lựa chọn hành động tối ưu theo nguyên lý Maximum Expected Utility (MEU) trong Decision Networks (Influence Diagrams).

⚡ *Hướng dẫn làm bài: Trả lời ngắn gọn, trực diện nhưng phải trình bày rõ công thức toán học và các bước biến đổi chi tiết. Với các câu hỏi mạng Bayes, nêu rõ phép phân rã phân phối chung (factorization) và các biến được lấy tổng (marginalization). Kết quả tính toán được làm tròn đến 4 chữ số thập phân kèm giá trị phân số chính xác.*

Bài 1. Cập nhật Bayes: Dự báo mưa cho lễ cưới

Marie tổ chức lễ cưới ngoài trời ở vùng sa mạc. Trong các năm gần đây, trung bình chỉ có 5 ngày mưa mỗi năm (1 năm chuẩn = 365 ngày). Dự báo thời tiết thông báo ngày mai sẽ mưa. Khi thực sự có mưa, hệ thống dự báo đúng mưa 90% thời gian; khi không mưa, hệ thống vẫn báo mưa nhầm 10% thời gian.

a) Xác định Prior P(Rain), Likelihood P(PredictRain|Rain) và P(PredictRain|¬Rain)

> 📌 **KẾT QUẢ XÁC ĐỊNH THAM SỐ XÁC SUẤT BAN ĐẦU**
>
> • Xác suất tiên nghiệm trời mưa (Prior): Trong 365 ngày của năm, trung bình có 5 ngày mưa:
> P(Rain) = 5 / 365 = 1 / 73 ≈ 0.0137 (1.37%)
> Xác suất tiên nghiệm trời không mưa:
> P(¬Rain) = 1 - P(Rain) = 360 / 365 = 72 / 73 ≈ 0.9863 (98.63%)
> • Khả năng dự báo mưa khi trời thực sự mưa (True Positive Rate / Likelihood):
> P(PredictRain | Rain) = 0.90 (90%)
> • Khả năng dự báo mưa nhầm khi trời thực tế không mưa (False Positive Rate):
> P(PredictRain | ¬Rain) = 0.10 (10%)

b) Tính P(PredictRain) bằng định luật xác suất toàn phần

> 📌 **TÍNH XÁC SUẤT TOÀN PHẦN CỦA BẰNG CHỨNG**
>
> Theo định luật xác suất toàn phần (Law of Total Probability):
> P(PredictRain) = P(PredictRain | Rain) · P(Rain) + P(PredictRain | ¬Rain) · P(¬Rain)

Thế các giá trị đã xác định ở câu a:

P(PredictRain) = 0.90 · (5 / 365) + 0.10 · (360 / 365)

= (4.5 / 365) + (36.0 / 365) = 40.5 / 365

= 81 / 730 ≈ 0.1110 (hay 11.10%)

=> Xác suất để hệ thống dự báo thông báo có mưa trong một ngày bất kỳ là xấp xỉ 11.10%.

c) Dùng định lý Bayes để tính xác suất thực tế trời mưa P(Rain|PredictRain)

📌 TÍNH XÁC SUẤT HẬU NGHIỆM THEO ĐỊNH LÝ BAYES

Theo định lý Bayes (Bayes' Theorem):

P(Rain | PredictRain) = [P(PredictRain | Rain) · P(Rain)] / P(PredictRain)

Thay các số hạng đã tính ở câu a và câu b:

P(Rain | PredictRain) = [0.90 · (5 / 365)] / [40.5 / 365]

= 4.5 / 40.5 = 1 / 9 ≈ 0.1111 (hay 11.11%)

=> Kết luận: Khi máy dự báo báo trời mưa, xác suất thực sự trời có mưa chỉ là 1/9 ≈ 11.11%.

d) So sánh xác suất trước và sau khi nhận dự báo. Bằng chứng mới làm niềm tin thay đổi theo hướng nào?

📌 SO SÁNH NIỀM TIN VÀ PHÂN TÍCH NGHỊCH LÝ TỶ LỆ NỀN

- Trước khi nhận dự báo (Prior belief): P(Rain) = 5/365 ≈ 0.0137 (1.37%).
- Sau khi nhận dự báo báo mưa (Posterior belief): P(Rain | PredictRain) = 1/9 ≈ 0.1111 (11.11%).
- Chiều hướng thay đổi của niềm tin: Bằng chứng mới ('dự báo trời mưa') làm niềm tin về khả năng trời mưa thay đổi theo CHIỀU HƯỚNG TĂNG MẠNH (tăng từ 1.37% lên 11.11%, gấp hơn 8.1 lần so với ban đầu).
- Nhận xét chuyên sâu (Nghịch lý tỷ lệ nền - Base-rate Fallacy): Dù xác suất mưa đã tăng mạnh gấp 8 lần, khả năng thực tế trời mưa vẫn rất thấp (chỉ ~11.11%, nghĩa là khả năng trời KHÔNG mưa vẫn áp đảo với 88.89%).

  Nguyên nhân: Do tỷ lệ nền (base rate) của ngày mưa tại sa mạc là cực hiếm (chỉ 5 ngày/năm). Số ngày nắng bị dự báo nhầm (10% của 360 ngày = 36 ngày) vượt trội hoàn toàn so với số ngày mưa được dự báo đúng (90% của 5 ngày = 4.5 ngày). Do đó, Marie hoàn toàn có cơ sở vững chắc để tiếp tục kế hoạch tổ chức tiệc cưới ngoài trời.

Bài 2. Ra quyết định dưới bất định: Bắt chuyến bay

Một tác tử phải chọn thời điểm rời nhà trước chuyến bay. Ký hiệu A_t là hành động rời nhà trước t phút. Tiện ích: U(on time) = 1000, U(missed flight) = -1000; chi phí chờ là 1 đơn vị cho mỗi phút rời sớm. Tiện ích của kết quả bằng tiện ích trạng thái trừ chi phí hành động.

Trạng thái / Hành	A25 (25 phút)	A90 (90 phút)	A120 (120 phút)	A1440 (1440 phút =

động				24h)
P(on time)	0.04	0.80	0.99	0.9999
P(missed flight)	0.96	0.20	0.01	0.0001

a) Viết công thức EU(A_t) cho một hành động bất kỳ

> **CÔNG THỨC TIỆN ÍCH KỲ VỌNG TỔNG QUÁT**
>
> Hàm tiện ích của kết quả khi thực hiện hành động A_t rời nhà trước t phút:
> • Nếu đến đúng giờ (on time): U(on time, A_t) = U(on time) - t = 1000 - t
> • Nếu trễ chuyến (missed flight): U(missed flight, A_t) = U(missed flight) - t = -1000 - t
> Công thức tính tiện ích kỳ vọng (Expected Utility) cho hành động A_t:
> EU(A_t) = Σ_{s} P(s | A_t) · U(s, A_t)
> = P(on time | A_t) · (1000 - t) + P(missed flight | A_t) · (-1000 - t)
> Vì P(on time | A_t) + P(missed flight | A_t) = 1, ta phân phối và rút gọn số hạng (-t):
> EU(A_t) = 1000 · P(on time | A_t) - 1000 · P(missed flight | A_t) - t
> EU(A_t) = 1000 · [P(on time | A_t) - P(missed flight | A_t)] - t

b) Tính EU(A25), EU(A90), EU(A120), EU(A1440)

> **TÍNH TOÁN TIỆN ÍCH KỲ VỌNG CHO TỪNG HÀNH ĐỘNG**
>
> 1. Với hành động A25 (t = 25 phút):
> EU(A25) = 1000 · (0.04 - 0.96) - 25 = 1000 · (-0.92) - 25 = -920 - 25 = -945
> 2. Với hành động A90 (t = 90 phút):
> EU(A90) = 1000 · (0.80 - 0.20) - 90 = 1000 · (0.60) - 90 = 600 - 90 = +510
> 3. Với hành động A120 (t = 120 phút = 2 giờ):
> EU(A120) = 1000 · (0.99 - 0.01) - 120 = 1000 · (0.98) - 120 = 980 - 120 = +860
> 4. Với hành động A1440 (t = 1440 phút = 24 giờ):
> EU(A1440) = 1000 · (0.9999 - 0.0001) - 1440 = 1000 · (0.9998) - 1440 = 999.8 - 1440 = -440.2

c) Theo nguyên lý MEU, tác tử nên chọn hành động nào? Giải thích ngắn gọn

> **KẾT LUẬN HÀNH ĐỘNG TỐI ƯU THEO MEU**
>
> • Theo nguyên lý Maximum Expected Utility (MEU), tác tử duy lý sẽ lựa chọn hành động có tiện ích kỳ vọng lớn nhất:
> a* = argmax_{a} EU(a) = A120 (với EU = +860)

- Thứ tự ưu tiên giữa các hành động: EU(A120) = 860 > EU(A90) = 510 > EU(A1440) = -440.2 > EU(A25) = -945.
- Giải thích ngắn gọn:

Hành động A120 (rời nhà trước 2 giờ) đạt được sự cân bằng tối ưu tuyệt hảo giữa rủi ro và chi phí:

- Đạt xác suất bắt kịp chuyến bay cực kỳ cao (99%), tránh được tổn thất rất lớn do trễ chuyến bay (-1000).
- Chi phí thời gian chờ đợi (120 phút) ở mức chấp nhận được.
- Rời nhà quá sát giờ (A25, A90) có nguy cơ trễ chuyến cao; trong khi rời nhà quá sớm (A1440 = 24 giờ) tuy xác suất kịp gần như tuyệt đối (99.99%) nhưng chi phí thời gian chờ đợi tại sân bay (1440 đơn vị) là quá lãng phí, khiến tiện ích tổng thể bị âm nặng (-440.2).

Bài 3. Độc lập và độc lập có điều kiện

Xét ba biến ngẫu nhiên Cavity (sâu răng), Toothache (đau răng) và Catch (đầu dò mắc vào lỗ sâu). Theo mô hình khám răng của nha sĩ, Toothache và Catch đều phụ thuộc vào Cavity.

a) Toothache và Catch có độc lập vô điều kiện không? Giải thích bằng trực giác xác suất

PHÂN TÍCH TÍNH ĐỘC LẬP VÔ ĐIỀU KIỆN

- Trả lời: KHÔNG độc lập vô điều kiện. Nghĩa là P(Toothache, Catch) ≠ P(Toothache) · P(Catch).
- Giải thích bằng trực giác xác suất:

Biến cố đau răng (Toothache) và que dò mắc lỗ sâu (Catch) đều là những triệu chứng lâm sàng bắt nguồn từ cùng một nguyên nhân gốc chung là sâu răng (Cavity).

Khi ta biết một bệnh nhân bị đau răng (Toothache = true), trực giác chỉ ra rằng khả năng bệnh nhân này bị sâu răng tăng lên đáng kể (P(Cavity | Toothache) > P(Cavity)).

Và khi xác suất bị sâu răng tăng lên, khả năng que dò nha khoa mắc vào lỗ răng sâu (Catch = true) cũng lập tức tăng theo (P(Catch | Toothache) > P(Catch)).

Vì việc quan sát Toothache làm thay đổi niềm tin về Catch, hai biến này phụ thuộc xác suất lẫn nhau khi chưa biết tình trạng Cavity (cấu trúc Common Cause / Fork).

b) Khi đã biết Cavity, Toothache và Catch có độc lập có điều kiện không? Viết ký hiệu độc lập có điều kiện

XÁC NHẬN VÀ KÝ HIỆU ĐỘC LẬP CÓ ĐIỀU KIỆN

- Trả lời: CÓ độc lập có điều kiện.
- Giải thích:

Khi nha sĩ đã chụp X-quang và BIẾT CHẮC CHẮN tình trạng có sâu răng hay không (Cavity đã biết), việc bệnh nhân có cảm thấy đau răng hay không hoàn toàn không cung cấp thêm bất kỳ bằng chứng vật lý mới nào về việc đầu que kim loại có móc trúng lỗ sâu hay không (việc que kim loại có mắc hay không chỉ phụ thuộc vật lý vào cấu trúc bề mặt men răng và sự tồn tại của lỗ sâu).

- Ký hiệu toán học chuẩn mực:

$\text{Toothache} \perp \text{Catch} \mid \text{Cavity}$

Hoặc viết dưới dạng xác suất có điều kiện:

$P(Toothache \mid Catch, Cavity) = P(Toothache \mid Cavity)$

$P(Toothache, Catch \mid Cavity) = P(Toothache \mid Cavity) \cdot P(Catch \mid Cavity)$

c) Dùng giả định độc lập có điều kiện để rút gọn P(Toothache, Catch, Cavity)

📌 RÚT GỌN PHÂN PHỐI XÁC SUẤT CHUNG

Theo quy tắc chuỗi xác suất tổng quát (Chain Rule of Probability):

$P(Toothache, Catch, Cavity) = P(Cavity) \cdot P(Toothache \mid Cavity) \cdot P(Catch \mid Toothache, Cavity)$

Áp dụng giả định độc lập có điều kiện ở câu b:

$P(Catch \mid Toothache, Cavity) = P(Catch \mid Cavity)$

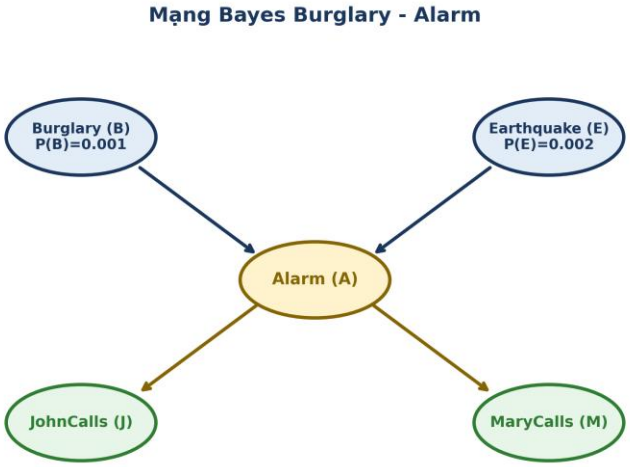
Biểu thức phân phối xác suất chung đầy đủ được rút gọn thành tích của 3 phân phối cục bộ:

$P(Toothache, Catch, Cavity) = P(Cavity) \cdot P(Toothache \mid Cavity) \cdot P(Catch \mid Cavity)$

=> Ý nghĩa: Phép rút gọn này giúp giảm số tham số độc lập cần lưu trữ từ $(2^3 - 1) = 7$ tham số xuống chỉ còn $1 + 2 + 2 = 5$ tham số độc lập.

Bài 4. Mạng Bayes Burglary-Alarm và phân phối xác suất chung

Xét mạng Bayes kinh điển Burglary-Alarm (Pearl, 1988). Các biến nhị phân gồm: B = Burglary, E = Earthquake, A = Alarm, J = JohnCalls, M = MaryCalls.



Hình 1: Cấu trúc mạng Bayes Burglary-Alarm và các bảng CPT đi kèm

a) Từ cấu trúc đồ thị, viết công thức phân rã đầy đủ cho P(B, E, A, J, M)

📌 CÔNG THỨC PHÂN RÃ PHÂN PHỐI CHUNG ĐẦY ĐỦ

Theo định lý nhân tử hóa của mạng Bayes (Factorization Theorem):

Phân phối xác suất chung đầy đủ bằng tích các xác suất có điều kiện của mỗi biến theo các biến cha (parents) của nó:

$P(X_1, ..., X_n) = \Pi_{i=1}^n P(X_i \mid Parents(X_i))$

Áp dụng cho đồ thị mạng Burglary-Alarm:

- Parents(B) = Ø => P(B)
- Parents(E) = Ø => P(E)
- Parents(A) = {B, E} => P(A | B, E)
- Parents(J) = {A} => P(J | A)
- Parents(M) = {A} => P(M | A)

Công thức phân rã đầy đủ:

$P(B, E, A, J, M) = P(B) \cdot P(E) \cdot P(A \mid B, E) \cdot P(J \mid A) \cdot P(M \mid A)$

b) Dùng CPT để tính xác suất của biến cố: B=true, E=false, A=true, J=true, M=true

📌 TÍNH TOÁN XÁC SUẤT ĐỒNG THỜI CỤ THỂ

Ký hiệu biến cố: (b, ¬e, a, j, m). Áp dụng công thức phân rã ở câu a:

$P(b, \neg e, a, j, m) = P(b) \cdot P(\neg e) \cdot P(a \mid b, \neg e) \cdot P(j \mid a) \cdot P(m \mid a)$

Tra cứu các giá trị từ bảng CPT đã cho:

- P(b) = 0.001
- P(¬e) = 1 - P(e) = 1 - 0.002 = 0.998
- P(a | b, ¬e) = 0.94
- P(j | a) = 0.90
- P(m | a) = 0.70

Thực hiện phép tính nhân liên tiếp:

$$P(b, \neg e, a, j, m) = 0.001 \cdot 0.998 \cdot 0.94 \cdot 0.90 \cdot 0.70$$
$$= 0.000998 \cdot 0.94 \cdot 0.63$$
$$= 0.00093812 \cdot 0.63 = 0.0005910156 \approx 5.9102 \times 10^{-4}$$

=> Làm tròn 4 chữ số thập phân: P(b, ¬e, a, j, m) ≈ 0.0006.

c) Vì sao mạng Bayes cần ít tham số hơn bảng Joint đầy đủ? So sánh số tham số của 5 biến Boolean

📌 SO SÁNH THAM SỐ GIỮA BẢNG JOINT VÀ MẠNG BAYES

1. Vì sao mạng Bayes cần ít tham số hơn?

Bảng phân phối xác suất chung đầy đủ (full joint distribution) phải chỉ định xác suất cho tất cả các trạng thái kết hợp đồng thời. Trong khi đó, mạng Bayes khai thác triệt để tính chất ĐỘC LẬP CÓ ĐIỀU KIỆN CỤC BỘ: mỗi biến độc lập có điều kiện với các nút không phải con cháu của nó khi biết các nút cha.

Do đó, thay vì một bảng khổng lồ, mạng Bayes chỉ cần các bảng CPT cục bộ nhỏ cho mỗi nút với các nút cha

trực tiếp của nó.

2. Đếm số tham số độc lập với 5 biến Boolean (B, E, A, J, M):

• Bảng Joint đầy đủ: Có $2^5 = 32$ trạng thái kết hợp. Vì tổng xác suất của toàn bộ 32 trạng thái phải bằng 1, số tham số độc lập tối thiểu cần là:

$2^5 - 1 = 32 - 1 = 31$ tham số độc lập.

• Mạng Bayes: Mỗi nút có k cha Boolean cần 2^k tham số độc lập:

- Nút B (0 cha): $2^0 = 1$ tham số (P(b))
- Nút E (0 cha): $2^0 = 1$ tham số (P(e))
- Nút A (2 cha B, E): $2^2 = 4$ tham số (P(a | B, E))
- Nút J (1 cha A): $2^1 = 2$ tham số (P(j | A))
- Nút M (1 cha A): $2^1 = 2$ tham số (P(m | A))

=> Tổng số tham số của mạng Bayes = 1 + 1 + 4 + 2 + 2 = 10 tham số độc lập.

=> Kết luận: Mạng Bayes giảm số tham số từ 31 xuống còn 10 (tiết kiệm hơn 67.7% tham số), giúp giảm bộ nhớ và lượng dữ liệu cần thiết để ước lượng.

d) Chỉ ra ít nhất hai phát biểu độc lập / độc lập có điều kiện suy ra từ cấu trúc mạng

📌 CÁC PHÁT BIỂU ĐỘC LẬP TỪ CẤU TRÚC MẠNG

Từ cấu trúc d-separation và Markov Blanket của mạng Burglary-Alarm, ta suy ra được các phát biểu chuẩn xác sau:

1. $B \perp E$ (Độc lập vô điều kiện):

Burglary và Earthquake độc lập vô điều kiện với nhau khi chưa quan sát biến cố con A (cấu trúc V-structure / collider tại nút A).

2. $J \perp M \mid A$ (Độc lập có điều kiện):

JohnCalls và MaryCalls độc lập có điều kiện khi đã biết chắc chắn trạng thái của chuông báo động Alarm (A đã chặn đường truyền d-separation giữa J và M, cấu trúc Fork / Common Cause).

3. $J \perp \{B, E\} \mid A$:

JohnCalls độc lập với Burglary và Earthquake khi đã biết trạng thái của chuông báo động Alarm.

4. $M \perp \{B, E\} \mid A$:

MaryCalls độc lập với Burglary và Earthquake khi đã biết trạng thái của chuông báo động Alarm.

Bài 5. Suy luận chính xác trong mạng Bayes

Vẫn sử dụng mạng Burglary-Alarm. Giả sử quan sát được John gọi và Mary gọi. Cần thực hiện suy luận xác suất có trộm: P(B | J=true, M=true).

a) Xác định biến truy vấn, biến bằng chứng và các biến ẩn cần lấy tổng

📌 PHÂN LOẠI CÁC BIẾN TRONG BÀI TOÁN SUY LUẬN

- Biến truy vấn (Query variable): B (Burglary - xác suất xảy ra trộm).
- Biến bằng chứng (Evidence variables): J = true (JohnCalls = true) và M = true (MaryCalls = true).
- Các biến chưa quan sát / biến ẩn cần lấy tổng (Hidden / Unobserved variables):
  E (Earthquake - động đất) và A (Alarm - chuông báo động).

b) Viết biểu thức suy luận bằng enumeration, bắt đầu từ quan hệ tỷ lệ

📌 BIỂU THỨC SUY LUẬN TỔNG QUÁT THEO ENUMERATION

Theo định lý Bayes và phép lấy tổng biên (Marginalization) trên các biến ẩn e và a:

$$P(B \mid j, m) \propto \Sigma_{e} \Sigma_{a} P(B, e, a, j, m)$$

Biểu thức đẳng thức với hằng số chuẩn hóa α (normalization constant):

$$P(B \mid j, m) = \alpha \cdot \Sigma_{e \in \{t, f\}} \Sigma_{a \in \{t, f\}} P(B, e, a, j, m)$$

Trong đó:

$$\alpha = 1 / P(j, m) = 1 / [\Sigma_{b} \Sigma_{e} \Sigma_{a} P(b, e, a, j, m)]$$

c) Thay phân rã mạng Bayes vào biểu thức trên và chỉ ra thứ tự các phép nhân / lấy tổng

📌 PHÂN TÍCH THỨ TỰ PHÉP NHÂN VÀ TRIỆT TIÊU BIẾN

1. Thay công thức phân rã của mạng Bayes vào biểu thức:

$$P(B \mid j, m) = \alpha \cdot \Sigma_{e} \Sigma_{a} [P(B) \cdot P(e) \cdot P(a \mid B, e) \cdot P(j \mid a) \cdot P(m \mid a)]$$

2. Đẩy các thừa số không phụ thuộc biến lấy tổng ra ngoài từng dấu tổng tương ứng:

$$P(B \mid j, m) = \alpha \cdot P(B) \cdot \Sigma_{e} P(e) \cdot \Sigma_{a} [P(a \mid B, e) \cdot P(j \mid a) \cdot P(m \mid a)]$$

3. Thứ tự các bước tính toán (từ trong ra ngoài - Inside-Out evaluation):
   - Bước 1: Với mỗi giá trị của a ∈ {t, f}, tính tích bằng chứng: $f_1(a) = P(j \mid a) \cdot P(m \mid a)$.
   - Bước 2 (Tổng theo a): Với mỗi cặp giá trị (B, e), tính tổng trên hai trạng thái a:
     $f_2(B, e) = \Sigma_{a \in \{t, f\}} P(a \mid B, e) \cdot f_1(a)$
   - Bước 3 (Tổng theo e): Với mỗi giá trị của B, tính tổng trên hai trạng thái e:
     $f_3(B) = \Sigma_{e \in \{t, f\}} P(e) \cdot f_2(B, e)$
   - Bước 4: Nhân với xác suất tiên nghiệm của biến truy vấn: $P(B, j, m) = P(B) \cdot f_3(B)$.
   - Bước 5 (Chuẩn hóa): Tính giá trị cho B = true và B = false, sau đó chuẩn hóa bằng hệ số α để tổng bằng 1:
     $P(b \mid j, m) = P(b, j, m) / [P(b, j, m) + P(\neg b, j, m)] \approx 0.2842$ (28.42%).

d) Giải thích tại sao suy luận chính xác bằng enumeration khó mở rộng khi số biến ẩn lớn

📌 GIẢI THÍCH HẠN CHẾ VỀ KHẢ NĂNG MỞ RỘNG CỦA ENUMERATION

• Bùng nổ tổ hợp hàm mũ (Exponential Complexity):

Nếu mạng có k biến ẩn nhị phân, thuật toán enumeration phải duyệt qua toàn bộ 2^k tổ hợp gán giá trị khả dĩ. Độ phức tạp thời gian trong trường hợp xấu nhất là $O(d^n)$ (với n là tổng số biến, d là lực lượng miền giá trị). Vấn đề suy luận chính xác trên mạng Bayes tổng quát đã được chứng minh là NP-hard (Cooper, 1990).

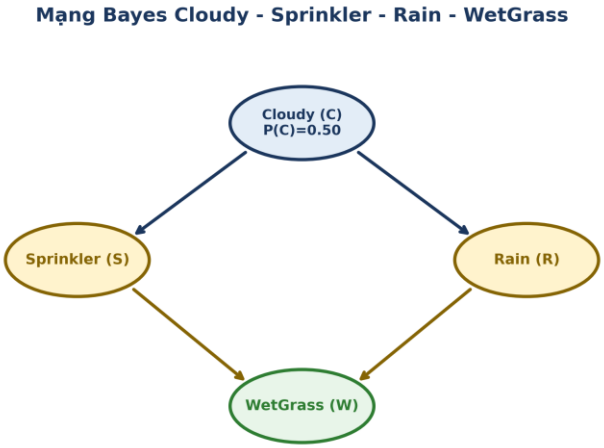
• Tính toán lặp thừa nghiêm trọng (Redundant Computations):

Enumeration duyệt cây đệ quy theo kiểu vét cạn không lưu trữ nhớ (không memoization), dẫn đến việc phải tính đi tính lại các biểu thức con giống nhau nhiều lần trên các nhánh khác nhau.

• Kết luận: Khi mạng có hàng chục hoặc hàng trăm biến ẩn, enumeration hoàn toàn bị tắc nghẽn và không thể thực thi trong thời gian chấp nhận được. Do đó trong thực tế, người ta phải dùng thuật toán tối ưu hơn như Variable Elimination, Junction Tree, hoặc chuyển sang các thuật toán suy luận xấp xỉ bằng lấy mẫu (Sampling / MCMC).

Bài 6. Suy luận xấp xỉ - Prior Sampling

Xét mạng Cloudy-Sprinkler-Rain-WetGrass. Mạng được dùng để minh họa thuật toán lấy mẫu tiên nghiệm Prior-Sample.



Hình 2: Mạng Bayes Cloudy-Sprinkler-Rain-WetGrass và thứ tự biến topo

a) Xác định một thứ tự lấy mẫu hợp lệ cho bốn biến và giải thích vì sao phải bắt đầu từ biến không có cha

📌 THỨ TỰ LẤY MẪU TOPO VÀ NGUYÊN TẮC KHỞI ĐẦU

• Thứ tự lấy mẫu hợp lệ (Topological Ordering):

Thứ tự 1: Cloudy → Sprinkler → Rain → WetGrass (C → S → R → W)

(Hoặc thứ tự 2: Cloudy → Rain → Sprinkler → WetGrass (C → R → S → W))

• Giải thích vì sao phải bắt đầu từ biến không có cha:

Trong mạng Bayes, xác suất của một nút bất kỳ được quy định bởi bảng CPT có điều kiện theo các nút cha của nó: P(X_i | Parents(X_i)). Để có thể sinh ngẫu nhiên một giá trị cho nút X_i, ta bắt buộc phải biết giá trị cụ thể đã được gán cho toàn bộ các nút cha của nó trước đó.

Nút không có cha (root node như Cloudy) chỉ có phân phối tiên nghiệm độc lập P(C), không phụ thuộc vào bất

kỳ biến nào khác, nên việc lấy mẫu bắt buộc phải khởi đầu từ nút gốc này rồi truyền xuôi theo chiều mũi tên qua các nút con.

b) Với C=true, đọc CPT ghi phân phối lấy mẫu S và R; nêu CPT dùng để lấy mẫu W

📌 CÁC PHÂN PHỐI ĐIỀU KIỆN TRONG BƯỚC LẤY MẪU CỤ THỂ

1. Lấy mẫu cho Sprinkler (S):

Tra bảng CPT P(S | C) tại dòng C = true:

P(S = true | C = true) = 0.10, P(S = false | C = true) = 0.90

=> Sinh số ngẫu nhiên $r_1 \in [0, 1)$: nếu $r_1 < 0.10$ thì gán S = true, ngược lại S = false.

2. Lấy mẫu cho Rain (R):

Tra bảng CPT P(R | C) tại dòng C = true:

P(R = true | C = true) = 0.80, P(R = false | C = true) = 0.20

=> Sinh số ngẫu nhiên $r_2 \in [0, 1)$: nếu $r_2 < 0.80$ thì gán R = true, ngược lại R = false.

3. Lấy mẫu cho WetGrass (W):

Sau khi đã sinh được cặp giá trị cụ thể (S = s, R = r) từ hai bước trên, ta dùng bảng CPT P(W | S, R) tra đúng dòng tương ứng với cặp (s, r) đó để lấy mẫu cho W:

- Nếu (s=true, r=true): dùng P(W=true) = 0.99, P(W=false) = 0.01
- Nếu (s=true, r=false): dùng P(W=true) = 0.90, P(W=false) = 0.10
- Nếu (s=false, r=true): dùng P(W=true) = 0.90, P(W=false) = 0.10
- Nếu (s=false, r=false): dùng P(W=true) = 0.01, P(W=false) = 0.99

c) Viết công thức ước lượng xác suất joint/marginal bằng Prior Sampling

📌 CÔNG THỨC ƯỚC LƯỢNG THEO LUẬT SỐ LỚN

Nếu thực hiện N mẫu mô phỏng và biến cố x (một phép gán trạng thái đầy đủ hoặc bộ phận) xuất hiện N_PS(x) lần, công thức ước lượng xác suất là tỷ lệ tần suất xuất hiện:

$\hat{P}(x) = N_PS(x) / N$

Ý nghĩa toán học:

Mỗi mẫu được sinh ra với xác suất chính xác bằng $P(x_1,...,x_n)$. Theo Luật số lớn (Law of Large Numbers), khi tổng số mẫu N tiến tới vô cùng, ước lượng tần suất này hội tụ tiệm cận về xác suất thực sự:

$\lim_{N \to \infty} [N_PS(x) / N] = P(x)$

d) So sánh ngắn gọn Prior Sampling với MCMC/Gibbs Sampling theo cách tạo chuỗi mẫu

📌 SO SÁNH CƠ CHẾ SINH CHUỖI MẪU

• Prior Sampling (Lấy mẫu tiên nghiệm):

- Cách tạo mẫu: Sinh các mẫu ĐỘC LẬP HOÀN TOÀN (i.i.d.). Mỗi mẫu mới được sinh độc lập từ đầu đến cuối theo thứ tự topo từ gốc đến lá.

- Mối quan hệ giữa các mẫu: Mẫu hiện tại hoàn toàn không phụ thuộc và không liên quan gì đến mẫu trước đó.

• MCMC / Gibbs Sampling (Lấy mẫu chuỗi Markov Monte Carlo):

- Cách tạo mẫu: Sinh một CHUỖI CÁC MẪU PHỤ THUỘC LẪN NHAU theo một chuỗi Markov.

- Cơ chế sinh: Mẫu tiếp theo x^{(t+1)} được tạo ra bằng cách giữ nguyên trạng thái mẫu hiện tại x^{(t)} và chỉ thay đổi giá trị của một biến duy nhất dựa trên phân phối điều kiện với Markov Blanket của biến đó.

- Đặc điểm: Các mẫu liên tiếp có độ tương quan cao; cần một giai đoạn làm nóng (burn-in period) để chuỗi hội tụ về phân phối dừng (stationary distribution).

Bài 7. Decision Network và Maximum Expected Utility

Xét bài toán quyết định mang ô. Weather ∈{sun, rain}; Action ∈{leave, take}. Không có dự báo thời tiết. P(sun)=0.7, P(rain)=0.3. Tiện ích U(A, W) cho trong bảng.

Hành động A (Action)	Thời tiết W (Weather)	Tiện ích U(A, W)
leave (để ô ở nhà)	sun (trời nắng)	100
leave (để ô ở nhà)	rain (trời mưa)	0
take (mang ô theo)	sun (trời nắng)	20
take (mang ô theo)	rain (trời mưa)	70

a) Tính EU(leave) và EU(take) từ P(Weather) và U(Action, Weather)

📌 TÍNH TOÁN TIỆN ÍCH KỲ VỌNG KHI CHƯA CÓ DỰ BÁO

1. Với hành động leave (để ô ở nhà):

EU(leave) = Σ_{w} P(w) · U(leave, w)

= P(sun) · U(leave, sun) + P(rain) · U(leave, rain)

= 0.7 · 100 + 0.3 · 0 = 70 + 0 = 70.0

2. Với hành động take (mang theo ô):

EU(take) = Σ_{w} P(w) · U(take, w)

= P(sun) · U(take, sun) + P(rain) · U(take, rain)

= 0.7 · 20 + 0.3 · 70 = 14 + 21 = 35.0

b) Chọn hành động tối ưu a* theo MEU và ghi MEU(Ø)

HÀNH ĐỘNG TỐI ƯU VÀ GIÁ TRỊ MEU(Ø)

- Theo nguyên lý Maximum Expected Utility (MEU):
  a* = argmax_{a ∈ {leave, take}} EU(a) = leave
- Tiện ích kỳ vọng cực đại khi chưa có bằng chứng (khi tập bằng chứng e = Ø):
  MEU(Ø) = max_{a} EU(a) = max(70.0, 35.0) = 70.0

=> Kết luận: Khi chưa có thông tin dự báo, tác tử tối ưu nên chọn để ô ở nhà (leave).

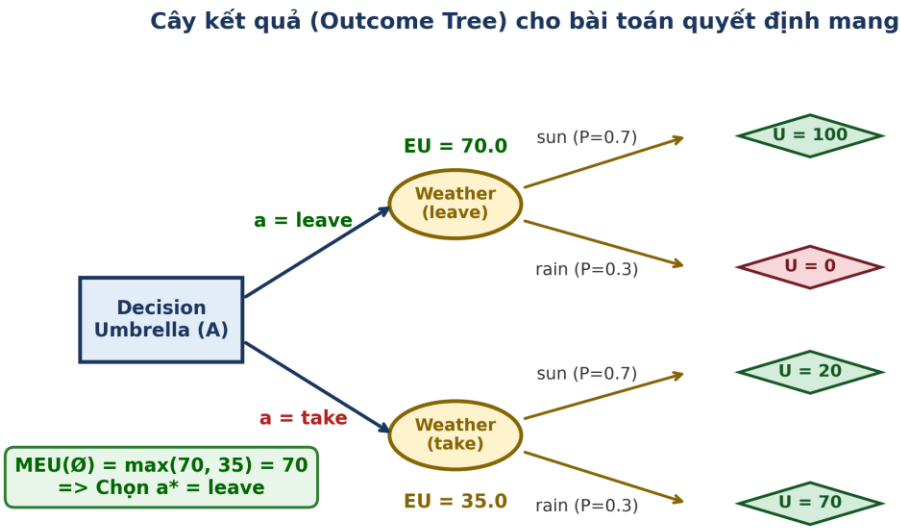
c) Vẽ cây kết quả (outcome tree) tương ứng

MÔ TẢ CẤU TRÚC CÂY KẾT QUẢ

Cây kết quả (Outcome Tree) được xây dựng với cấu trúc:

- Gốc là Nút quyết định (Hình vuông): Umbrella (A) gồm 2 nhánh: leave và take.
- Tiếp theo là Nút ngẫu nhiên (Hình tròn): Weather cho mỗi nhánh, rẽ thành sun (P=0.7) và rain (P=0.3).
- Các nút lá là Nút tiện ích (Hình kim cương) thể hiện giá trị U tương ứng.

Hình minh họa cây kết quả hoàn chỉnh được trình bày bên dưới:



Hình 3: Cây kết quả (Outcome Tree) minh họa quá trình tính MEU cho bài toán mang ô

Bài 8. Decision Network khi có bằng chứng

Giả sử tác tử nhận bằng chứng Forecast = bad. Sau khi cập nhật niềm tin bằng định lý Bayes, xác suất hậu nghiệm là P(sun|bad) = 0.34 và P(rain|bad) = 0.66. Bảng tiện ích giữ nguyên như bài trước.

a) Tính EU(leave|bad) và EU(take|bad)

TÍNH TOÁN TIỆN ÍCH KỲ VỌNG KHI CÓ DỰ BÁO XẤU

1. Với hành động leave (để ô ở nhà):

EU(leave | bad) = Σ_{w} P(w | bad) · U(leave, w)

= P(sun | bad) · U(leave, sun) + P(rain | bad) · U(leave, rain)

= 0.34 · 100 + 0.66 · 0 = 34.0 + 0 = 34.0

2. Với hành động take (mang ô theo):

EU(take | bad) = Σ_{w} P(w | bad) · U(take, w)

= P(sun | bad) · U(take, sun) + P(rain | bad) · U(take, rain)

= 0.34 · 20 + 0.66 · 70 = 6.8 + 46.2 = 53.0

b) Hành động tối ưu sau khi quan sát dự báo có thay đổi so với khi chưa có dự báo không? Nêu nguyên nhân

SO SÁNH VÀ GIẢI THÍCH NGUYÊN NHÂN THAY ĐỔI QUYẾT ĐỊNH

- Quyết định tối ưu mới theo MEU:

  a*(bad) = argmax_{a} EU(a | bad) = take (với MEU(bad) = max(34.0, 53.0) = 53.0)
- Kết luận so sánh: CÓ THAY ĐỔI.

  - Khi chưa có dự báo (Bài 7): Hành động tối ưu là leave (EU = 70.0).

  - Sau khi quan sát dự báo thời tiết xấu (Forecast = bad): Hành động tối ưu CHUYỂN SANG take (EU = 53.0).
- Nguyên nhân:

  Bằng chứng 'Forecast = bad' đã làm thay đổi căn bản phân phối niềm tin về thời tiết: xác suất trời mưa tăng vọt từ 30% lên 66% (chiếm đa số áp đảo), trong khi xác suất trời nắng sụt giảm từ 70% xuống chỉ còn 34%.

  Khi khả năng mưa chiếm tới 66%, nếu để ô ở nhà (leave), tác tử sẽ đối mặt nguy cơ 66% nhận tiện ích bằng 0 (bị ướt mưa hoàn toàn). Ngược lại, việc mang ô (take) đem lại tiện ích cao (70) khi trời mưa, đủ sức bù đắp cho sự phiền hà nhỏ nếu trời nắng (tiện ích 20), do đó hành động mang ô trở nên vượt trội.

c) Giải thích vai trò của ba loại nút trong Decision Network: chance node, action node và utility node

VAI TRÒ VÀ KÝ HIỆU CỦA BA LOẠI NÚT TRONG DECISION NETWORK

1. Nút ngẫu nhiên (Chance node) - Ký hiệu hình tròn / hình bầu dục (Oval):

   • Đại diện cho các biến ngẫu nhiên trong môi trường mà tác tử không thể trực tiếp kiểm soát (ví dụ: Weather, Forecast).

   • Mỗi nút ngẫu nhiên đi kèm một bảng phân phối xác suất có điều kiện (CPT) phụ thuộc vào các nút cha của nó.

2. Nút hành động / quyết định (Action / Decision node) - Ký hiệu hình chữ nhật (Rectangle):

• Đại diện cho các quyết định mà tác tử có quyền tự do lựa chọn và kiểm soát hoàn toàn (ví dụ: Umbrella ∈ {leave, take}).

• Các cung đi vào nút hành động đại diện cho thông tin/bằng chứng mà tác tử đã biết tại thời điểm ra quyết định.

3. Nút tiện ích (Utility node) - Ký hiệu hình kim cương (Diamond):

• Đại diện cho hàm mục tiêu / hàm tiện ích U của tác tử, lượng hóa mức độ ưa thích hay sự thỏa mãn của tác tử đối với từng trạng thái kết quả của thế giới.

• Nút tiện ích chỉ nhận các cung đi vào từ các nút hành động và nút ngẫu nhiên liên quan, không có cung đi ra.

Bài 9. MAP và Naïve Bayes

Một tác tử phân loại cần suy luận giả thuyết H từ các đặc trưng F_1, ..., F_n. Quyết định MAP (Maximum A Posteriori) với hàm mất mát 0-1 loss:

$h^* = \text{argmax}_{h} P(f_1, ..., f_n \mid h) \cdot P(h) \iff h^* = \text{argmax}_{h} P(h \mid f_1, ..., f_n)$

a) Giải thích vì sao mẫu số P(evidence) có thể bỏ khi thực hiện argmax

GIẢI THÍCH TOÁN HỌC VIỆC BỎ MẪU SỐ TRONG TOÁN TỬ ARGMAX

Theo định lý Bayes, xác suất hậu nghiệm của giả thuyết h khi quan sát bằng chứng $e = (f_1, ..., f_n)$ là:

$P(h \mid f_1, ..., f_n) = [\, P(f_1, ..., f_n \mid h) \cdot P(h) \,] / P(f_1, ..., f_n)$

Trong đó mẫu số là xác suất biên của bằng chứng:

$P(f_1, ..., f_n) = \Sigma_{h'} P(f_1, ..., f_n \mid h') \cdot P(h')$

• Giải thích vì sao bỏ được mẫu số:

1. Mẫu số $P(f_1, ..., f_n)$ là hằng số dương giống nhau đối với mọi ứng viên giả thuyết h đang được xét (nó độc lập hoàn toàn với biến tối ưu h).

2. Việc chia cho một hằng số dương không làm thay đổi thứ tự so sánh (order-preserving) giữa các giá trị hàm mục tiêu của các giả thuyết khác nhau.

3. Do đó, vị trí của giả thuyết đạt cực đại h* không hề thay đổi khi bỏ qua mẫu số, giúp tiết kiệm đáng kể thời gian tính toán mà kết quả dự đoán vẫn chính xác 100%.

b) Nếu mỗi đặc trưng có k giá trị, bảng likelihood tổng quát tăng theo bậc nào khi có n đặc trưng?

QUY MÔ TĂNG TRƯỞNG HÀM MŨ CỦA BẢNG LIKELIHOOD TỔNG QUÁT

• Giả sử có n đặc trưng rời rạc $F_1, ..., F_n$, mỗi đặc trưng có thể nhận k giá trị khác nhau.

• Số lượng trạng thái kết hợp đồng thời khả dĩ của n đặc trưng là $k \cdot k \cdot ... \cdot k = k^n$ trạng thái.

• Do đó, với mỗi giả thuyết h, bảng likelihood tổng quát $P(f_1, ..., f_n \mid h)$ cần chỉ định k^n giá trị xác suất (với $k^n - 1$ tham số độc lập).

• Nếu có $|H|$ lớp/giả thuyết, tổng số tham số likelihood cần lưu trữ là $|H| \cdot (k^n - 1)$.

=> Kết luận: Bảng likelihood tổng quát tăng theo BẬC HÀM MŨ (Exponential scale) theo số lượng đặc trưng: $O(k^n)$ (hay $O(|H| \cdot k^n)$).

Hệ quả: Đây chính là hiện tượng 'thảm họa số chiều' (Curse of Dimensionality). Khi n tăng lên vài chục hoặc vài trăm, bảng likelihood sẽ bùng nổ vượt quá kích thước bộ nhớ và đòi hỏi lượng dữ liệu huấn luyện khổng lồ mà không tập dữ liệu thực tế nào đáp ứng nổi.

c) Nêu giả định Naïve Bayes và viết công thức MAP sau khi dùng giả định độc lập có điều kiện

GIẢ ĐỊNH VÀ CÔNG THỨC MAP CỦA NAÏVE BAYES

• Giả định Naïve Bayes (Naïve Bayes Assumption):

Giả định rằng TẤT CẢ CÁC ĐẶC TRƯNG $F_1, F_2, ..., F_n$ ĐỘC LẬP CÓ ĐIỀU KIỆN VỚI NHAU KHI ĐÃ BIẾT LỚP / GIẢ THUYẾT H:

$P(f_1, f_2, ..., f_n \mid h) = \Pi_{i=1}^{n} P(f_i \mid h) = P(f_1 \mid h) \cdot P(f_2 \mid h) \cdot ... \cdot P(f_n \mid h)$

• Công thức MAP sau khi áp dụng giả định Naïve Bayes:

$h^* = \text{argmax}_{h} [P(h) \cdot \Pi_{i=1}^{n} P(f_i \mid h)]$

• Dưới dạng log-likelihood (chuẩn trong lập trình thực tế để tránh tràn số thực dưới - underflow):

$h^* = \text{argmax}_{h} [\ln P(h) + \Sigma_{i=1}^{n} \ln P(f_i \mid h)]$

=> Ưu điểm vượt trội: Số lượng tham số cần ước lượng giảm từ hàm mũ $O(|H| \cdot k^n)$ xuống chỉ còn bậc tuyến tính $O(|H| \cdot n \cdot k)$, cho phép mô hình huấn luyện cực nhanh và hoạt động hiệu quả ngay cả trên các tập dữ liệu có số chiều rất lớn.

Bài 10. Câu hỏi tổng hợp Đúng/Sai và giải thích

Đánh giá tính Đúng/Sai của 10 phát biểu lý thuyết nền tảng kèm giải thích chi tiết, chuẩn xác theo lý thuyết xác suất và trí tuệ nhân tạo.

1) Nếu X và Y độc lập thì P(X,Y) = P(X)P(Y).

KẾT QUẢ ĐÁNH GIÁ: ĐÚNG

• ĐÁP ÁN: ĐÚNG

• Giải thích: Đây chính là định nghĩa toán học nền tảng của hai biến cố / biến ngẫu nhiên độc lập trong lý thuyết xác suất. Khi độc lập, P(X|Y) = P(X), dẫn tới P(X,Y) = P(X|Y)P(Y) = P(X)P(Y).

2) Trong cấu trúc common effect X→Y←Z, X và Z độc lập khi chưa quan sát Y, nhưng có thể trở nên phụ thuộc khi biết Y.

KẾT QUẢ ĐÁNH GIÁ: ĐÚNG

• ĐÁP ÁN: ĐÚNG

• Giải thích: Đây là cấu trúc V-structure (Collider). Theo tiêu chuẩn d-separation, khi Y (và con cháu của Y) chưa được quan sát, đường truyền bị chặn nên X và Z độc lập vô điều kiện ($X \perp Z$). Nhưng khi quan sát Y, đường truyền được kích hoạt (unblocked), sinh ra hiện tượng 'giải thích phụ trợ' (explaining away), khiến X và Z trở nên phụ thuộc có điều kiện ($X \not\perp Z \mid Y$).

3) Mạng Bayes phải là một đồ thị có hướng không chu trình (DAG).

📌 KẾT QUẢ ĐÁNH GIÁ: ĐÚNG

• ĐÁP ÁN: ĐÚNG

• Giải thích: Mạng Bayes bắt buộc phải là DAG (Directed Acyclic Graph) để đảm bảo không có vòng lặp phụ thuộc luẩn quẩn (circular dependency). Nhờ đó, phân phối xác suất chung có thể phân rã nhất quán và hợp lệ theo quy tắc chuỗi mà không vi phạm tiên đề xác suất.

4) Một mạng Bayes cùng các CPT chứa đủ thông tin để xác định phân phối xác suất chung.

📌 KẾT QUẢ ĐÁNH GIÁ: ĐÚNG

• ĐÁP ÁN: ĐÚNG

• Giải thích: Theo định lý nhân tử hóa của mạng Bayes, toàn bộ phân phối xác suất chung đầy đủ (full joint distribution) được tái tạo hoàn chỉnh bằng tích các CPT cục bộ: $P(X_1,...,X_n) = \Pi\ P(X_i \mid Parents(X_i))$. Do đó, mạng và các CPT chứa trọn vẹn thông tin về phân phối joint.

5) Suy luận exact bằng enumeration luôn mở rộng tốt khi số biến ẩn tăng.

📌 KẾT QUẢ ĐÁNH GIÁ: SAI

• ĐÁP ÁN: SAI

• Giải thích: Suy luận chính xác bằng enumeration có độ phức tạp thời gian theo hàm mũ O(d^k) với k là số biến ẩn. Khi số biến ẩn tăng lên, không gian trạng thái bùng nổ tổ hợp cấp số nhân khiến thuật toán chạy cực kỳ chậm và không thể mở rộng được (bài toán suy luận trên mạng Bayes tổng quát là NP-hard).

6) Prior Sampling phải lấy mẫu theo thứ tự topo của mạng.

KẾT QUẢ ĐÁNH GIÁ: ĐÚNG

• ĐÁP ÁN: ĐÚNG

• Giải thích: Vì xác suất của một nút phụ thuộc trực tiếp vào giá trị của các nút cha ($P(X_i \mid Parents(X_i))$), ta bắt buộc phải lấy mẫu giá trị của các nút cha trước rồi mới có điều kiện tra bảng CPT để lấy mẫu cho các nút con. Điều này đòi hỏi quá trình duyệt phải tuân thủ đúng thứ tự sắp xếp topo.

7) Decision Network là mạng Bayes được bổ sung nút hành động và nút tiện ích.

KẾT QUẢ ĐÁNH GIÁ: ĐÚNG

• ĐÁP ÁN: ĐÚNG

• Giải thích: Decision Network (còn gọi là Influence Diagram) mở rộng mạng Bayes bằng cách tích hợp thêm hai thành phần mới: các nút quyết định/hành động (Action nodes - hình chữ nhật) và các nút tiện ích (Utility nodes - hình kim cương) để hỗ trợ lý thuyết quyết định duy lý.

8) Tác tử hợp lý theo lý thuyết quyết định chọn hành động có tiện ích kỳ vọng lớn nhất.

KẾT QUẢ ĐÁNH GIÁ: ĐÚNG

• ĐÁP ÁN: ĐÚNG

• Giải thích: Đây chính là nguyên lý Maximum Expected Utility (MEU) – tiêu chuẩn vàng xác định hành vi của một tác tử duy lý (rational agent) khi hoạt động trong môi trường có tính bất định.

9) Với 0-1 loss, quyết định MAP chọn giá trị có posterior lớn nhất.

KẾT QUẢ ĐÁNH GIÁ: ĐÚNG

• ĐÁP ÁN: ĐÚNG

• Giải thích: Trong lý thuyết quyết định Bayes, với hàm mất mát 0-1 loss (phạt 0 nếu đoán đúng, phạt 1 nếu đoán sai), rủi ro kỳ vọng (Expected Risk) đạt giá trị nhỏ nhất khi và chỉ khi ta chọn giả thuyết h có xác suất hậu nghiệm $P(h|e)$ cao nhất (Maximum A Posteriori).

10) Naïve Bayes giả sử các đặc trưng độc lập hoàn toàn, kể cả khi chưa biết lớp.

KẾT QUẢ ĐÁNH GIÁ: SAI

• ĐÁP ÁN: SAI

• Giải thích: Naïve Bayes chỉ giả định các đặc trưng ĐỘC LẬP CÓ ĐIỀU KIỆN KHI ĐÃ BIẾT LỚP ($F_i \perp F_j \mid H$). Khi CHƯA biết lớp, các đặc trưng KHÔNG hề độc lập vô điều kiện với nhau (marginal independence), bởi chính biến lớp H đóng vai trò là nguyên nhân chung liên kết và tạo ra sự tương quan giữa các đặc trưng.

Bài 11. Tổng hợp quy trình tác tử Bayes ra quyết định

Mô tả quy trình 6 bước chuẩn khoa học của một tác tử quyết định theo lý thuyết Bayes (Decision-Theoretic Agent): từ Prior/Likelihood, nhận Evidence, cập nhật Belief, dự đoán kết quả hành động, tính Expected Utility đến chọn hành động tối ưu theo MEU.

Bước 1: Khởi tạo mô hình thế giới và hàm tiện ích (Prior & Likelihood & Utility Modeling)

• Tác tử thiết lập không gian trạng thái S, không gian hành động A, và không gian bằng chứng E.
• Khởi tạo phân phối xác suất tiên nghiệm P(S) phản ánh niềm tin ban đầu của tác tử về trạng thái thế giới.
• Xây dựng mô hình cảm biến (sensor model / likelihood) P(E | S) mô tả xác suất phát sinh các quan sát từ trạng thái thực tế.
• Thiết lập hàm tiện ích U(S', a) lượng hóa mức độ ưa thích hay giá trị lợi ích của kết quả đạt được.

Bước 2: Thu nhận bằng chứng từ môi trường (Perceive Evidence)

• Tác tử tiếp nhận các quan sát thực tế từ thế giới thực thông qua hệ thống cảm biến.
• Bằng chứng thu nhận được tổng hợp thành vector quan sát cụ thể: $e = (e_1, e_2, ..., e_k)$.

Bước 3: Cập nhật niềm tin hậu nghiệm bằng định lý Bayes (Update Belief via Bayes' Rule)

• Tác tử kết hợp niềm tin tiên nghiệm P(S) với bằng chứng mới quan sát được e thông qua định lý Bayes để cập nhật trạng thái niềm tin (belief state) thành phân phối hậu nghiệm:
$P(S \mid e) = \alpha \cdot P(e \mid S) \cdot P(S) = [\, P(e \mid S) \cdot P(S) \,] \,/\, P(e)$
• Phân phối P(S | e) này phản ánh mức độ chắc chắn chính xác nhất của tác tử về thế giới hiện tại.

Bước 4: Dự đoán kết quả chuyển trạng thái của các hành động (Predict Action Outcomes)

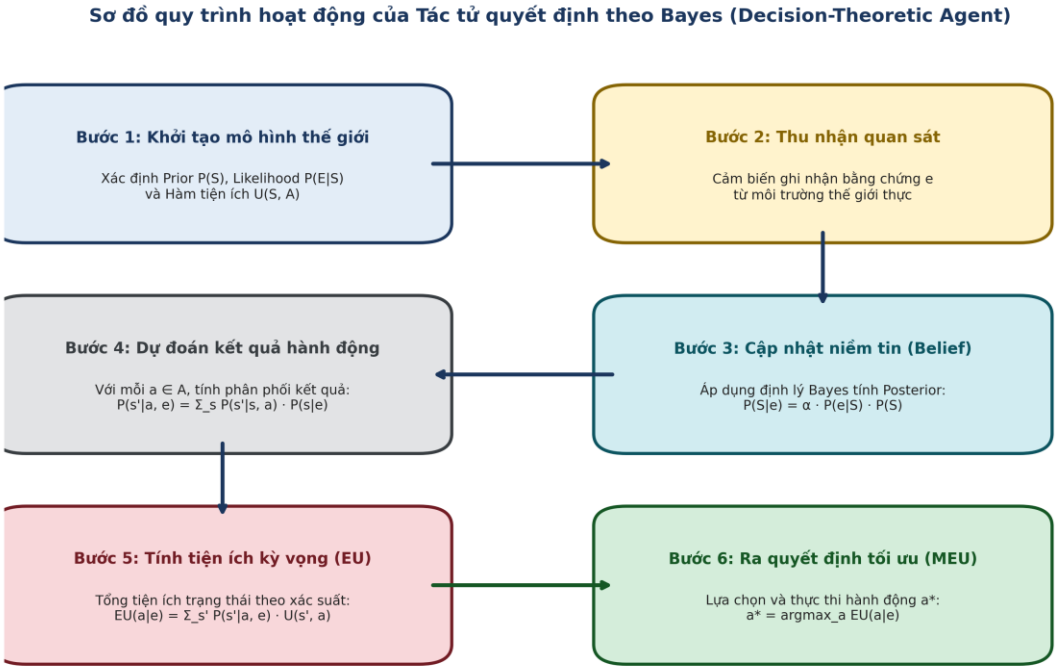
• Với mỗi hành động ứng viên $a \in A$, tác tử dự báo phân phối xác suất của trạng thái kết quả tương lai s' bằng cách kết hợp niềm tin hiện tại với mô hình chuyển tiếp môi trường (transition model) P(s' | s, a):
$P(s' \mid a, e) = \Sigma_{s} P(s' \mid s, a) \cdot P(s \mid e)$
• Nếu kết quả phụ thuộc trực tiếp vào trạng thái hiện tại s, bước này chính là phân phối điều kiện P(s | e).

Bước 5: Tính toán tiện ích kỳ vọng cho từng hành động (Compute Expected Utility - EU)

• Tác tử tính toán tiện ích kỳ vọng của từng hành động a bằng cách lấy tổng có trọng số xác suất của các trạng thái kết quả khả dĩ:
$EU(a \mid e) = \Sigma_{s'} P(s' \mid a, e) \cdot U(s', a)$
• Giá trị EU này phản ánh 'điểm chất lượng' tổng thể của từng hành động dưới góc nhìn đánh đổi giữa rủi ro và lợi ích.

Bước 6: Lựa chọn và thực thi hành động tối ưu theo nguyên lý MEU (Select Optimal Action via MEU)

• Tác tử ra quyết định lựa chọn hành động a* mang lại tiện ích kỳ vọng lớn nhất:
a* = argmax_{a ∈ A} EU(a | e)
• Tác tử gửi lệnh điều khiển tới các cơ cấu chấp hành (actuators) để thực thi hành động a* ra môi trường thực tế, hoàn tất một chu kỳ cảm nhận - suy luận - hành động.



Hình 4: Sơ đồ luồng 6 bước của Tác tử quyết định theo lý thuyết Bayes

Bài 12. Phân lớp Dog/Cat bằng Naïve Bayes

Cho tập huấn luyện 10 đối tượng. Ba đặc trưng nhị phân: f_1 = Is it big? (Lớn?), f_2 = Does it follow people? (Theo người?), f_3 = Does it like to take a walk? (Thích đi dạo?). Nhãn lớp: Dog hoặc Cat. Cần phân lớp đối tượng mới X_{11} có đặc trưng: (f_1=YES, f_2=NO, f_3=NO).

No.	f_1: Lớn? (Is it big?)	f_2: Theo người? (Follow people?)	f_3: Thích đi dạo? (Take a walk?)	Lớp (Class)
1	YES	YES	YES	**Dog**
2	YES	YES	NO	**Cat**
3	NO	YES	YES	**Dog**
4	YES	YES	YES	**Dog**
5	NO	NO	YES	**Cat**
6	YES	NO	YES	**Dog**
7	YES	NO	YES	**Cat**

8	NO	NO	NO	**Cat**
9	YES	YES	YES	**Dog**
10	NO	YES	NO	**Dog**

a) Từ bảng dữ liệu, tính prior P(Dog) và P(Cat)

📌 TÍNH XÁC SUẤT TIÊN NGHIỆM PRIOR

Tổng số mẫu trong tập huấn luyện: N = 10.

- Đếm số lượng mẫu thuộc lớp Dog: gồm các mẫu 1, 3, 4, 6, 9, 10 => N(Dog) = 6 mẫu.
  P(Dog) = N(Dog) / N = 6 / 10 = 0.60 (60%)
- Đếm số lượng mẫu thuộc lớp Cat: gồm các mẫu 2, 5, 7, 8 => N(Cat) = 4 mẫu.
  P(Cat) = N(Cat) / N = 4 / 10 = 0.40 (40%)

b) Tính các likelihood cần thiết cho X_{11} = (f_1=YES, f_2=NO, f_3=NO)

📌 TÍNH TOÁN CÁC LIKELIHOOD TƯƠNG ỨNG

1. Với lớp Dog (N(Dog) = 6 mẫu: 1, 3, 4, 6, 9, 10):
   - f_1 = YES: gồm các mẫu 1, 4, 6, 9 (4 mẫu) => P(f_1=YES | Dog) = 4/6 = 2/3 ≈ 0.6667
   - f_2 = NO: gồm mẫu 6 (1 mẫu) => P(f_2=NO | Dog) = 1/6 ≈ 0.1667
   - f_3 = NO: gồm mẫu 10 (1 mẫu) => P(f_3=NO | Dog) = 1/6 ≈ 0.1667
2. Với lớp Cat (N(Cat) = 4 mẫu: 2, 5, 7, 8):
   - f_1 = YES: gồm các mẫu 2, 7 (2 mẫu) => P(f_1=YES | Cat) = 2/4 = 1/2 = 0.5000
   - f_2 = NO: gồm các mẫu 5, 7, 8 (3 mẫu) => P(f_2=NO | Cat) = 3/4 = 0.7500
   - f_3 = NO: gồm các mẫu 2, 8 (2 mẫu) => P(f_3=NO | Cat) = 2/4 = 1/2 = 0.5000

c) Dùng giả định độc lập có điều kiện của Naïve Bayes tính Score(Dog) và Score(Cat)

📌 TÍNH ĐIỂM SỐ CHƯA CHUẨN HÓA (SCORES)

1. Đại lượng chưa chuẩn hóa cho lớp Dog:
   Score(Dog) = P(Dog) · P(f_1=YES | Dog) · P(f_2=NO | Dog) · P(f_3=NO | Dog)
   = (6/10) · (4/6) · (1/6) · (1/6) = (4/10) · (1/36)
   = 4 / 360 = 1 / 90 ≈ 0.01111... ≈ 0.0111
2. Đại lượng chưa chuẩn hóa cho lớp Cat:
   Score(Cat) = P(Cat) · P(f_1=YES | Cat) · P(f_2=NO | Cat) · P(f_3=NO | Cat)
   = (4/10) · (2/4) · (3/4) · (2/4) = 0.4 · 0.5 · 0.75 · 0.5

= 0.4 · 0.1875 = 0.0750 = 3 / 40

d) Giải thích 'zero-frequency problem', áp dụng Laplace smoothing (+1) và tính lại hai score

ÁP DỤNG LÀM TRƠN LAPLACE VÀ TÍNH LẠI SCORES

• Giải thích hiện tượng 'zero-frequency problem':

Trong Naïve Bayes, xác suất hậu nghiệm tỷ lệ thuận với tích các likelihood: Score(c) = P(c) Π P(f_i|c). Nếu một giá trị đặc trưng nào đó chưa từng xuất hiện cùng với một lớp trong tập dữ liệu huấn luyện, likelihood tương ứng sẽ bằng 0 (P(f_i|c) = 0). Do phép nhân tích, giá trị 0 này sẽ triệt tiêu toàn bộ Score(c) về 0, bất chấp tất cả các đặc trưng khác có cung cấp bằng chứng mạnh mẽ đến mức nào ủng hộ lớp đó. Đây là biểu hiện của overfitting do kích thước mẫu hạn chế.

• Áp dụng Laplace smoothing (+1) với đặc trưng nhị phân (K = 2 giá trị {YES, NO}):

P_Laplace(f_i | c) = [count(f_i, c) + 1] / [N(c) + 2]

1. Với lớp Dog (N = 6, mẫu số = 6 + 2 = 8):

- P_Laplace(f_1=YES | Dog) = (4 + 1) / (6 + 2) = 5/8 = 0.6250
- P_Laplace(f_2=NO | Dog) = (1 + 1) / (6 + 2) = 2/8 = 0.2500
- P_Laplace(f_3=NO | Dog) = (1 + 1) / (6 + 2) = 2/8 = 0.2500

Score_Laplace(Dog) = (6/10) · (5/8) · (2/8) · (2/8) = (6/10) · (20 / 512)
= 120 / 5120 = 3 / 128 ≈ 0.0234375 ≈ 0.0234

2. Với lớp Cat (N = 4, mẫu số = 4 + 2 = 6):

- P_Laplace(f_1=YES | Cat) = (2 + 1) / (4 + 2) = 3/6 = 0.5000
- P_Laplace(f_2=NO | Cat) = (3 + 1) / (4 + 2) = 4/6 ≈ 0.6667
- P_Laplace(f_3=NO | Cat) = (2 + 1) / (4 + 2) = 3/6 = 0.5000

Score_Laplace(Cat) = (4/10) · (3/6) · (4/6) · (3/6) = (4/10) · (36 / 216)
= (4/10) · (1/6) = 4 / 60 = 1 / 15 ≈ 0.066667 ≈ 0.0667

e) Kết luận lớp dự đoán của X_{11} trước và sau khi smoothing. Nhận xét sự khác biệt

KẾT LUẬN DỰ ĐOÁN VÀ NHẬN XÉT SO SÁNH

1. Trước khi làm trơn (Without smoothing):
   - Score(Dog) ≈ 0.0111 < Score(Cat) = 0.0750.
   - Chuẩn hóa xác suất hậu nghiệm:

     P(Cat | X_{11}) = 0.0750 / (0.0750 + 0.0111) ≈ 87.1%

     P(Dog | X_{11}) = 0.0111 / (0.0750 + 0.0111) ≈ 12.9%

   => Kết luận: Dự đoán đối tượng X_{11} thuộc lớp CAT (Mèo).
2. Sau khi làm trơn Laplace (With Laplace smoothing):
   - Score_Laplace(Dog) ≈ 0.0234 < Score_Laplace(Cat) ≈ 0.0667.
   - Chuẩn hóa xác suất hậu nghiệm:

P(Cat | X_{11}) = 0.0667 / (0.0667 + 0.0234) ≈ 74.0%

P(Dog | X_{11}) = 0.0234 / (0.0667 + 0.0234) ≈ 26.0%

=> Kết luận: Dự đoán đối tượng X_{11} VẪN THUỘC LỚP CAT (Mèo).

3. Nhận xét sự khác biệt:

• Quyết định phân lớp cuối cùng không thay đổi (đều là Cat).

• Tuy nhiên, Laplace smoothing đã điều chỉnh các ước lượng xác suất cực đoan về gần phân phối đều hơn: Score của Dog tăng lên gấp đôi (từ 0.0111 lên 0.0234) trong khi Score của Cat giảm nhẹ (từ 0.0750 xuống 0.0667).

• Khoảng cách xác suất giữa hai lớp được thu hẹp (từ tỷ lệ ~6.75:1 giảm xuống còn ~2.85:1), làm giảm độ tự tin thái quá (overconfidence) khi tập dữ liệu huấn luyện còn nhỏ, giúp mô hình ổn định và tổng quát hóa tốt hơn.

Bài 13. Naïve Bayes với thuộc tính rời rạc và liên tục

Cho tập dữ liệu 10 hồ sơ kê khai thuế (Tan, Steinbach, Kumar, 2005). Các thuộc tính gồm: Refund (Hoàn thuế), Marital Status (Tình trạng hôn nhân), Taxable Income (Thu nhập chịu thuế, liên tục) và Class ∈{Yes, No} (Gian lận thuế). Cần phân lớp bản ghi mới: x = (Refund = No, Marital Status = Married, Taxable Income = 120K).

Tid	Refund	Marital Status	Taxable Income	Class (Cheat?)
1	Yes	Single	125K	**No**
2	No	Married	100K	**No**
3	No	Single	70K	**No**
4	Yes	Married	120K	**No**
5	No	Divorced	95K	**Yes**
6	No	Married	60K	**No**
7	Yes	Divorced	220K	**No**
8	No	Single	85K	**Yes**
9	No	Married	75K	**No**
10	No	Single	90K	**Yes**

a) Tính prior P(Class=No) và P(Class=Yes)

XÁC SUẤT TIÊN NGHIỆM HAI LỚP

Tổng số hồ sơ trong tập dữ liệu: N = 10.

• Lớp No (không gian lận): gồm 7 hồ sơ (Tid 1, 2, 3, 4, 6, 7, 9) => N(No) = 7.

P(Class = No) = 7 / 10 = 0.70 (70%)

- Lớp Yes (có gian lận): gồm 3 hồ sơ (Tid 5, 8, 10) => N(Yes) = 3.
  P(Class = Yes) = 3 / 10 = 0.30 (30%)

b) Với hai thuộc tính rời rạc, tính các likelihood và chỉ ra likelihood bằng 0

TÍNH TOÁN LIKELIHOOD THUỘC TÍNH RỜI RẠC

1. Với lớp Class = No (N(No) = 7 hồ sơ: 1, 2, 3, 4, 6, 7, 9):
   - Refund = No: gồm các mẫu 2, 3, 6, 9 (4 mẫu) => P(Refund=No | No) = 4/7 ≈ 0.5714
   - Marital Status = Married: gồm các mẫu 2, 4, 6, 9 (4 mẫu) => P(Married | No) = 4/7 ≈ 0.5714
2. Với lớp Class = Yes (N(Yes) = 3 hồ sơ: 5, 8, 10):
   - Refund = No: gồm cả 3 mẫu 5, 8, 10 (3 mẫu) => P(Refund=No | Yes) = 3/3 = 1.0000
   - Marital Status = Married: không có mẫu nào (0 mẫu) => P(Married | Yes) = 0/3 = 0.0000
- Chỉ ra likelihood bằng 0:
  Likelihood bằng 0 là: P(Marital Status = Married | Class = Yes) = 0.

c) Với Taxable Income là biến liên tục Gaussian, tính mật độ p(120K|No) và p(120K|Yes)

TÍNH TOÁN THAM SỐ GAUSSIAN VÀ MẬT ĐỘ XÁC SUẤT

Hàm mật độ xác suất phân phối chuẩn (Gaussian Probability Density Function):

$p(x \mid c) = [\ 1 / (\sqrt{(2\pi \cdot s^2)})\ ] \cdot \exp(\ -\ (x - \mu)^2 / (2 \cdot s^2)\ )$

1. Với lớp Class = No (tập 7 giá trị thu nhập: 125, 100, 70, 120, 60, 220, 75):
   - Giá trị trung bình mẫu (Sample Mean):
     $\mu_No = (125 + 100 + 70 + 120 + 60 + 220 + 75) / 7 = 770 / 7 = 110$
   - Phương sai mẫu (Sample Variance với bậc tự do n - 1 = 6):
     $s^2_No = [\ (125-110)^2 + (100-110)^2 + (70-110)^2 + (120-110)^2 + (60-110)^2 + (220-110)^2 + (75-110)^2\ ] / 6$
     $= [\ 225 + 100 + 1600 + 100 + 2500 + 12100 + 1225\ ] / 6 = 17850 / 6 = 2975$
     Độ lệch chuẩn mẫu: $s_No = \sqrt{2975} \approx 54.5436$
   - Mật độ xác suất tại x = 120:
     $p(Income = 120K \mid No) = [\ 1 / (\sqrt{(2\pi \cdot 2975)})\ ] \cdot \exp(\ -\ (120 - 110)^2 / (2 \cdot 2975)\ )$
     $= [\ 1 / (54.5436 \cdot 2.5066)\ ] \cdot \exp(\ -\ 100 / 5950\ )$
     $= [\ 1 / 136.721\ ] \cdot \exp(-0.016807) \approx 0.0073142 \cdot 0.983334$
     ≈ 0.007192 (hay 0.0072)
2. Với lớp Class = Yes (tập 3 giá trị thu nhập: 95, 85, 90):
   - Giá trị trung bình mẫu (Sample Mean):
     $\mu_Yes = (95 + 85 + 90) / 3 = 270 / 3 = 90$
   - Phương sai mẫu (Sample Variance với bậc tự do n - 1 = 2):
     $s^2_Yes = [\ (95-90)^2 + (85-90)^2 + (90-90)^2\ ] / 2 = [\ 25 + 25 + 0\ ] / 2 = 25$

Độ lệch chuẩn mẫu: $s_Yes = \sqrt{25} = 5$

- Mật độ xác suất tại x = 120:

$p(Income = 120K \mid Yes) = [\ 1 / (5 \cdot \sqrt{(2\pi)})\ ] \cdot \exp(\ -\ (120 - 90)^2 / (2 \cdot 25)\ )$

$= [\ 1 / 12.5331\ ] \cdot \exp(\ -\ 900 / 50\ ) = 0.079788 \cdot \exp(-18)$

$\approx 0.079788 \cdot (1.523 \times 10^{-8}) \approx 1.215 \times 10^{-9} \approx 0.0000000012$

d) Không dùng smoothing, tính Score(No) và Score(Yes). Kết luận lớp dự đoán

TÍNH TOÁN VÀ DỰ ĐOÁN KHI CHƯA SMOOTHING

1. Tính đại lượng chưa chuẩn hóa cho lớp No:

$Score(No) = P(No) \cdot P(Refund=No \mid No) \cdot P(Married \mid No) \cdot p(120K \mid No)$

$= 0.7 \cdot (4/7) \cdot (4/7) \cdot 0.007192$

$= 0.4 \cdot (4/7) \cdot 0.007192 = (1.6 / 7) \cdot 0.007192$

$\approx 0.22857 \cdot 0.007192 \approx 0.001644$ (hay 1.644×10^{-3})

2. Tính đại lượng chưa chuẩn hóa cho lớp Yes:

$Score(Yes) = P(Yes) \cdot P(Refund=No \mid Yes) \cdot P(Married \mid Yes) \cdot p(120K \mid Yes)$

$= 0.3 \cdot 1.0 \cdot 0 \cdot (1.215 \times 10^{-9}) = 0.0000$

- So sánh và Kết luận lớp dự đoán:

Ta thấy Score(No) = 0.001644 > Score(Yes) = 0.

=> Kết luận: Bản ghi mới x được phân loại vào lớp NO (Class = No, không gian lận thuế).

e) Áp dụng Laplace smoothing cho thuộc tính rời rạc, tính lại Score(No) và Score(Yes). Có thay đổi lớp dự đoán không?

KẾT QUẢ TÍNH TOÁN SAU KHI LÀM TRƠN LAPLACE

Quy định số giá trị rời rạc: Refund có $K_1 = 2$ giá trị {Yes, No}; Marital Status có $K_2 = 3$ giá trị {Single, Married, Divorced}.

1. Tính các likelihood sau khi áp dụng Laplace smoothing:

- Thuộc tính Refund ($K_1 = 2$):
  - Lớp No (N=7): $P_Laplace(Refund=No \mid No) = (4 + 1) / (7 + 2) = 5/9 \approx 0.5556$
  - Lớp Yes (N=3): $P_Laplace(Refund=No \mid Yes) = (3 + 1) / (3 + 2) = 4/5 = 0.8000$
- Thuộc tính Marital Status ($K_2 = 3$):
  - Lớp No (N=7): $P_Laplace(Married \mid No) = (4 + 1) / (7 + 3) = 5/10 = 0.5000$
  - Lớp Yes (N=3): $P_Laplace(Married \mid Yes) = (0 + 1) / (3 + 3) = 1/6 \approx 0.1667$ (đã khắc phục giá trị 0!)

2. Tính lại Score sau khi smoothing:

- $Score_Laplace(No) = P(No) \cdot P_Laplace(Refund=No \mid No) \cdot P_Laplace(Married \mid No) \cdot p(120K \mid No)$

$= 0.7 \cdot (5/9) \cdot 0.50 \cdot 0.007192$

$\approx 0.7 \cdot 0.55556 \cdot 0.5 \cdot 0.007192 \approx 0.001398$ (hay 1.398×10^{-3})

• Score_Laplace(Yes) = P(Yes) · P_Laplace(Refund=No | Yes) · P_Laplace(Married | Yes) · p(120K | Yes)

$= 0.3 \cdot 0.80 \cdot (1/6) \cdot (1.215 \times 10^{-9})$

$= 0.04 \cdot (1.215 \times 10^{-9}) \approx 4.86 \times 10^{-11}$

3. So sánh và Kết luận:

Score_Laplace(No) $\approx 1.398 \times 10^{-3}$ >> Score_Laplace(Yes) $\approx 4.86 \times 10^{-11}$.

=> KHÔNG THAY ĐỔI LỚP DỰ ĐOÁN, bản ghi x vẫn được phân loại chắc chắn vào lớp NO.

Giải thích: Mặc dù Laplace smoothing đã giải cứu likelihood bị triệt tiêu về 0 của Marital Status, nhưng mức thu nhập 120K nằm quá xa giá trị trung bình 90K của lớp Yes (cách tới 6 lần độ lệch chuẩn σ=5), khiến mật độ Gaussian của lớp Yes rơi vào vùng đuôi cực tiểu (~10^{-9}), do đó lớp No vẫn hoàn toàn áp đảo.

f) Vì sao Gaussian Naïve Bayes dùng mật độ xác suất thay vì xác suất tại một điểm? Nêu hạn chế của giả định độc lập

PHÂN TÍCH LÝ THUYẾT MẬT ĐỘ GAUSSIAN VÀ HẠN CHẾ MÔ HÌNH

1. Vì sao Gaussian Naïve Bayes dùng mật độ xác suất (Probability Density Function - PDF)?

• Trong lý thuyết xác suất, đối với biến ngẫu nhiên liên tục X, tập giá trị là vô hạn liên tục. Do đó, xác suất để biến nhận chính xác một giá trị số thực duy nhất bất kỳ luôn bằng 0: $P(X = x) = 0$.

• Để xét xác suất, ta phải tính trên một khoảng vi phân lân cận nhỏ xung quanh x: $P(x \le X \le x + \varepsilon) \approx p(x) \cdot \varepsilon$ (với $\varepsilon > 0$ rất nhỏ).

• Khi so sánh xác suất hậu nghiệm giữa các lớp c_1 và c_2 để tìm argmax:

$[P(c_1 \mid x)] / [P(c_2 \mid x)] \approx [P(c_1) \cdot p(x \mid c_1) \cdot \varepsilon] / [P(c_2) \cdot p(x \mid c_2) \cdot \varepsilon] = [P(c_1) \cdot p(x \mid c_1)] / [P(c_2) \cdot p(x \mid c_2)]$

• Độ rộng khoảng vi phân ε xuất hiện đồng nhất ở mọi lớp nên triệt tiêu lẫn nhau hoàn toàn. Do đó, việc thay thế trực tiếp xác suất bằng giá trị hàm mật độ xác suất p(x) = f(x) là hoàn toàn hợp lý về mặt toán học và bảo toàn 100% thứ tự xếp hạng argmax.

2. Hạn chế của giả định độc lập có điều kiện trong bài toán kê khai thuế này:

• Giả định Naïve Bayes xem các đặc trưng độc lập có điều kiện khi biết nhãn Class thường KHÔNG THỎA MÃN trong thực tế tài chính:

- Tương quan giữa Marital Status (Tình trạng hôn nhân) và Taxable Income (Thu nhập): Những người đã kết hôn (Married) thường có độ tuổi, quy mô gia đình, số nguồn thu và biểu thuế khác biệt rõ rệt so với người độc thân (Single) hay ly hôn (Divorced).

- Tương quan giữa Refund (Hoàn thuế) và Taxable Income (Thu nhập): Khả năng được xét hoàn thuế phụ thuộc trực tiếp vào mức thu nhập chịu thuế và các khoản giảm trừ gia cảnh.

• Việc mô hình bỏ qua sự tương quan mạnh mẽ này sẽ dẫn đến hiện tượng 'thổi phồng bằng chứng' (overcounting / double counting evidence), khiến ước lượng xác suất hậu nghiệm trở nên quá tự tin và có thể dẫn tới phán đoán sai lệch ở các trường hợp biên.